



第1章 嵌入式系统基础

本章主要内容

1.1 嵌入式系统简介

1.2 嵌入式处理器

1.3 嵌入式系统开发环境

1.4 嵌入式操作系统

1.5 边缘智能 (Edge AI)

本章教学要求

1、了解

- 嵌入式系统的特点
- 嵌入式系统的应用
- 嵌入式处理器。

2、理解

- 嵌入式计算机系统与通用计算机系统
- 开发环境
- 嵌入式操作系统
- 实时操作系统。

3、掌握

- 嵌入式系统定义
- 嵌入式系统的组成
- 嵌入式系统的分类
- 嵌入式处理器的选择
- 开发工具的选择
- 硬件调试工具的选择
- 软件组件的选择
- 常见的嵌入式操作系统名称。

1.1 嵌入式系统简介

1.1.1 嵌入式系统定义

一、嵌入式系统定义

通常的定义：嵌入式系统是以应用为中心，以计算机技术为基础，采用可剪裁软硬件，适用于对功能、可靠性、成本、体积、功耗等有严格要求的**专用计算机系统**。

通俗的定义：嵌入到**对象体系中的专用计算机系统**。

嵌入性、专用性与计算机系统是嵌入式系统的三个基本要素。

1.1 嵌入式系统简介

二、对嵌入式系统的理解

- ① 专用性：嵌入式系统是面向用户、面向产品、面向应用的；
- ② 计算机系统：嵌入式系统是将先进的计算机技术、半导体技术、电子技术和各个行业的具体应用相结合的产物；
- ③ 嵌入性：嵌入式系统必须根据应用需求对软硬件进行裁剪，满足应用系统的功能、可靠性、成本、体积等要求。嵌入式系统核心就定制硬、软件。

凡是与产品结合在一起的具有嵌入式特点的控制系統都可以叫嵌入式系统。

1.1 嵌入式系统简介

1.1.2 嵌入式系统的组成

包括 **硬件** 和 **软件** 两部分。

- 硬件部分是整个系统的物理基础，它提供软件运行平台和通信接口；
- 软件部分实际控制系统的运行。

对应两种嵌入式系统结构模型：


应用(Application)
设备驱动程序
底层硬件

应用程序(Application)
标准接口函数(API)
操作系统(OS)
硬件抽象层(HAL)、 BSP、驱动
底层硬件

1.1 嵌入式系统简介

一、嵌入式系统硬件部分

嵌入式系统的硬件包括：核心处理器、外围电路 和 外部设备三部分，如下图所示：



1.1 嵌入式系统简介

①核心处理器

嵌入式系统的硬件层的核心是嵌入式微处理器。

嵌入式微处理器可以采用 冯·诺依曼体系结构 和 哈佛体系结构；指令系统可以采用 精简指令集系统 和 复杂指令集系统。

1.1 嵌入式系统简介


(1) 冯.诺依曼体系结构 和 哈佛体系结构

A、冯.诺依曼体系结构

冯.诺依曼结构也称为普林斯顿结构，是一种将 **程序指令存储器** 和 **数据存储器** 合并在一起的存储器结构。

单次取指令长度和取数据的**长度相同**。

ARM7——冯.诺依曼体系结构



1.1 嵌入式系统简介

B、哈佛结构


哈佛结构：是一种将 **程序指令存储** 和 **数据存储** 分开的存储器结构。

程序指令存储和数据存储分开，可以使指令和数据有 **不同的数据宽度**。

ARM9

内部结构是哈佛结构（即处理器内核是哈佛结构）

芯片整体看是冯.诺依曼结构



1.1 嵌入式系统简介

(2) 精简指令集系统 和 复杂指令集系统

CISC: 复杂指令集 (Complex Instruction Set Computer)

- 具有大量的指令和寻址方式。
- 大多数程序只使用少量的指令就能够运行。

RISC: 精简指令集 (Reduced Instruction Set Computer)

- 8/2原则: 80%的程序只使用20%的指令。
 - 只包含最有用的指令。
 - 确保数据通道快速执行每一条指令。
 - 使CPU硬件结构设计变得更为简单。
-

1.1 嵌入式系统简介


RISC 和 CISC 之间主要的差别

指标	RISC	CISC
指令集	一个周期执行一条指令，通过简单指令的组合实现复杂操作，指令长度固定。	指令长度不固定，执行需要多个周期。
流水线	流水线每周期前进一步	指令的执行需要调用一段微程序
寄存器	更多通用寄存器	用于特定目的的专用寄存器
Load/Store结构	独立的Load/Store指令完成数据在寄存器和外部存储器之间的传输	处理器能够直接处理存储器中的数据

1.1 嵌入式系统简介

②外围电路


外围电路包括：嵌入式系统的存储器、I/O端口、复位电路、模数转换器/数模转换器（ADC/DAC）和电源。



1.1 嵌入式系统简介

③外部设备

外部设备指嵌入式系统与真实环境交互的各种设备，包括：通用串行总线（USB）、存储设备、键盘、鼠标、液晶显示器（LCD）、红外数据传输（IrDA）和打印设备等。



1.1 嵌入式系统简介

二、嵌入式系统软件部分

由嵌入式操作系统和嵌入式应用软件两大部分组成。

嵌入式系统软件一般包含四个层面：应用程序、应用程序接口API、实时操作系统RTOS、硬件抽象层（HAL）。有的版本将应用程序接口 API 归属于 OS 层，就是按照三层来划分的。

应用程序(Application)
标准接口函数(API)
操作系统(OS)
硬件抽象层(HAL)、 BSP、驱动
底层硬件

1.1 嵌入式系统简介

1.1.3 嵌入式系统的特点

嵌入式系统同通用计算机系统相比有以下特点：

- ①专用性强
 - ②强调实时性
 - ③具备可裁剪性
 - ④可靠性要求高
 - ⑤功耗低
 - ⑥嵌入式系统开发需要开发工具和开发环境
-

1.1 嵌入式系统简介

嵌入式系统的核心是嵌入式微处理器。嵌入式微处理器一般就具备以下4个特点：

- 对实时多任务有很强的支持能力。
- 具有功能很强的存储区保护功能。
- 可扩展的处理器结构。
- 嵌入式微处理器功耗低。

1.1 嵌入式系统简介

1.1.4 嵌入式系统的分类

按处理器位数划分

- 4位嵌入式系统
- 8位嵌入式系统
- 16位嵌入式系统
- 32位嵌入式系统
- 64位嵌入式系统

按实时性划分

- 非实时系统 (PDA)
- 软实时系统 (电子消费类产品)
- 硬实时系统 (数控、航空航天等工业和军工系统)

1.1 嵌入式系统简介

1.1.4 嵌入式系统的分类

按软件结构划分

- 循环轮询系统
- 前后台系统
- 单处理器多任务系统
- 多处理器多任务系统

按应用划分

- 通信类
- 信息家电类
- 移动终端类
- 汽车电子类
- 工业控制类
- ...

1.1 嵌入式系统简介

1.1.5 嵌入式系统的应用

嵌入式系统技术具有非常广阔的应用前景，其应用领域主要包括以下方面：

- (1) 工业控制；
 - (2) 交通管理；
 - (3) 信息家电；
 - (4) 家庭智能管理系统；
 - (5) POS网络及电子商务；
 - (6) 环境工程与自然；
 - (7) 机器人。
-

1.2 嵌入式处理器

1.2.1 嵌入式处理器简介

目前具有嵌入式功能特点的处理器已有千种，流行体系结构包括 MCU、MPU 等几十个系列。

嵌入式处理器包括从：单片机、DSP 到 FPGA 有着各式各样的品种，运算速度越来越快，性能越来越强，价格也越来越低。

1.2 嵌入式处理器

1.2.2 嵌入式处理器分类

(1) 嵌入式微处理器 (MPU)

嵌入式微处理器是由通用计算机中的CPU演变而来的。

嵌入式微处理器的特征：是具有较高的性能，但价格也较高。

和工业控制计算机相比：嵌入式微处理器做的控制机具有体积小、重量轻、成本低、可靠性高的优点。

1.2 嵌入式处理器

(2) 嵌入式微控制器 (MCU)

嵌入式微控制器的典型代表就是单片机。

和嵌入式微处理器相比：微控制器的最大特点是单片化，体积大大减少，从而使功耗和成本下降、可靠性提高。

由于 MCU 低廉的价格、优良的功能，所以拥有的品种和数量最多。目前 MCU 占嵌入式系统 70% 的市场份额。

1.2 嵌入式处理器

(3) 嵌入式DSP处理器

DSP 处理器是专门用于信号处理方面的处理器。

其在系统的结构和指令算法方面进行了特殊的设计。

目前最为广泛应用的是 TI 的TMS320C2000/C5000 /C6000系列等。

1.2 嵌入式处理器

(4) SOC片上系统

一个芯片就是一个系统，或将一个系统放在一个芯片中。

SOC最大特点是实现了软/硬件的无缝结合，直接在处理器芯片内部嵌入操作系统代码模块。

1.3 嵌入式系统开发环境

(1) 开发工具的选择

嵌入式系统的开发工具可以分为：**硬件开发工具** 和 **软件开发工具**。

- 硬件开发工具包括：在线实时仿真器和其他检测工具，如示波器等。
- 软件开发工具包括：编辑、交叉编译、链接、定位软件和调试软件等。
- 在选择开发工具时要考虑：系统调试器的功能，特别是远程调试的功能，还有该工具支持的库函数。
- 还要考虑开发工具的后续升级支持，支持的文件格式和符号格式 等。

1.3 嵌入式系统开发环境

(2) 硬件调试工具的选择

- ①实时在线仿真器（ICE）；
- ②逻辑分析仪；
- ③ROM仿真器。

(3) 软件组件的选择

(4) 开发环境

- ①交叉环境；
 - ②指令模拟器；
 - ③电路开发板。
-

1.4 嵌入式操作系统

1.4.1 嵌入式操作系统

嵌入式操作系统EOS (Embedded Operating System) 是支持嵌入式系统应用的操作系统，是软、硬件资源的控制中心。

嵌入系统的全部软、硬件资源的分配、调度工作由 EOS 负责，也控制和协调并发活动。

1.4 嵌入式操作系统

EOS 是相对于一般操作系统而言的，它除具备了一般操作系统最基本的功能如：任务调度、同步机制、中断处理、文件功能等外，还有以下特点：

- ① 可装卸性；
 - ② 强实时性；
 - ③ 强稳定性，弱交互性；
 - ④ 固化代码；
 - ⑤ 更好的硬件适应性，也就是良好的移植性。
-

1.4 嵌入式操作系统

1.4.2 实时操作系统

嵌入式操作系统可分为：**实时操作系统** 和 **非实时操作系统**。

实时操作系统是指——能在确定的时间内执行其功能并**对外部的异步事件**做出响应的计算机系统。其操作的正确性不仅依赖于**逻辑设计的正确程度**，而且与这些操作进行的**时间**有关。

实时操作系统的首要任务是调度一切可利用的资源完成实时控制任务，其次才是着眼于系统的使用效率。

1.4 嵌入式操作系统

一、几个实时操作系统中的重要概念：

(1) 系统响应时间

系统收到处理要求到系统给出应答信号的时间。

(2) 任务换道时间

任务之间切换使用的时间。

(3) 中断延迟

计算机接收到中断信号到操作系统作出响应，并完成换道转入中断服务程序的时间。

1.4 嵌入式操作系统

一、几个实时操作系统中的重要概念：

实时操作系统中的任务有四个状态：**运行、就绪、挂起、冬眠。**

- ① 运行：获得 CPU 的控制权。
 - ② 就绪：进入任务就绪(等待)队列，等待通过调度转为运行状态。
 - ③ 挂起：任务发生阻塞，移出任务就绪队列，等待系统实时事件的发生而唤醒，从而转为 就绪 或 运行。
 - ④ 冬眠：任务完成 或 错误 等原因被清除的任务，也可以认为是系统中不存在的任务。
-

1.4 嵌入式操作系统

二、实时操作系统的分类

按实时性的要求，可分为：

- 软实时系统：要求任务在规定时间内完成，超时不会造成系统失效或灾难性后果，体现为系统功能的服务质量下降。
- 硬实时系统：任务必须在规定的时间内完成，一旦超时会造成系统失效或灾难性后果，例如应用在化工厂、核电站的硬实时系统。

按任务是否可被抢占，分为

- 不可抢占型系统
 - 可抢占型系统
-

1.4 嵌入式操作系统

1.4.3 常见的嵌入式操作系统

(1) Linux操作系统简介

嵌入式 Linux 的特点：

1. Linux 是开放源代码的；
2. Linux 的内核小、效率高，内核的更新速度很快；
3. Linux 是免费的 OS，在价格上极具竞争力。

1.4 嵌入式操作系统

嵌入式 Linux 系统产品主要分为三类：

第一：专门为 Linux 的嵌入式方向做的

如何让 Linux 更小、更容易嵌入到体积要求和功能、性能要求更高的硬件中去，是产品的开发方向，如 Monta Vista 的 Hard Hat Linux 等。

第二：专门为 Linux 的实时特性设计的产品

将 Linux 开发成实时操作系统，尤其是硬实时系统，应用于一些关键的控制场合。如 Fsm labs 公司的 RT-Linux。

第三：将实时性和嵌入式方案结合起来的方案，并且提供集成化的解决方案。如 Lineo、TimeSys 等。

1.4 嵌入式操作系统

uCLinux

- uCLinux 是一个完全符合 GNU/GPL （GNU通用公共许可证）公约的操作系统，完全开放源代码。
 - uCLinux 从 Linux2.0/2.4内核派生出来，沿袭了主流Linux 的绝大部分特性。
 - uCLinux 是专门针对没有 MMU 的 CPU，并且为嵌入式系统做了许多小型化的工作，适用于没有虚拟内存或内存管理单元（MMU）的处理器。
-

1.4 嵌入式操作系统

(2) Android

Android 是一种基于 Linux 的自由及开放源代码的操作系统，主要使用于移动设备，如智能手机和平板电脑，由 Google 公司和开放手机联盟领导及开发。

Android 最初由 Andy Rubin 开发，主要支持手机。2005年8月 由 Google 收购注资。2007年11月，Google与84家硬件制造商、软件开发商及电信营运商组建开放手机联盟共同研发改良Android系统。

1.4 嵌入式操作系统

(2) Android

Android优势：

1. 开放性；
2. 丰富的硬件；
3. 方便开发；
4. Google应用。

1.4 嵌入式操作系统

(3) Windows CE

Windows CE 是一个全新开发的操作系统，是一个开放的、可裁剪的、32位的实时嵌入式窗口操作系统。

与其它操作系统相比，Windows CE 操作系统具有可靠性好、实时性高、可以广泛应用于：嵌入式智能设备的开发、工业控制、信息家电、移动通讯、汽车电子等各个领域。

Windows CE 的图形用户界面相当出色，它不仅继承了传统的 Windows 图形界面，并且在 Windows CE 平台上可以使用 Windows 的很多开发工具。

1.4 嵌入式操作系统

Windows CE 的基本特性如下：

1. 适应小型系统，为低成本、计算能力较差的系统提供简洁、高效、完善的控制机制；
2. 支持多种处理器和计算机架构，并支持多种装置接口；
3. 遵循Windows平台的应用开发规范，提供Win32API等；
4. 操作系统各部分模块化，可根据特性定制，以适应ROM；
5. 为应用程序提供网络通信、图形使用接口、数据库、档案等支持；
6. 支持实时应用；
7. 提供进阶电源管理功能。

1.4 嵌入式操作系统

(4) 鸿蒙(HarmonyOS)

华为公司开发的HarmonyOS是面向多智能终端、全场景的分布式操作系统。鸿蒙操作系统的核心特点：

- ① 分布式架构与软总线技术，实现跨设备协同能力；
- ② 微内核与高安全性；
- ③ 确定时延引擎与高实时性；
- ④ 轻量化与低资源占用；
- ⑤ 一次开发、多端部署；

1.4 嵌入式操作系统

(4) VxWorks

VxWorks 操作系统是美国WindRiver公司于1983年设计开发的一种嵌入式实时操作系统（RTOS）。

VxWorks具有良好的持续发展能力、高性能的内核以及友好的用户开发环境，具有**良好的可靠性和卓越的实时性**，在嵌入式实时操作系统领域占据一席之地。

VxWorks被广泛的应用于通信、军事、航空、航天等 高精尖技术及实时性要求极高的领域中。如卫星通讯、军事演习、导弹制导、飞机导航等。

1.4 嵌入式操作系统

(5) uC/os-II

uC/os-II是一种基于优先级的抢占式多任务实时操作系统，包含了：实时内核、任务管理、时间管理、任务间通信同步（信号量、邮箱、消息队列）和内存管理等功能。

uC/os-II可以使各个任务独立工作，互不干涉，很容易实现准时而且无误执行，使实际应用程序的设计和扩展变得容易，使应用程序的设计过程大为简单。

uC/os-II绝大部分的代码是用ANSI的C语言写的，和微处理器硬件相关的部分是用汇编语言写的。

1.4 嵌入式操作系统

(5) uC/os-II

至今，从8位到64位，uC/os-II已在超过40种不同架构的微处理器运行。还通过了联邦航空局（FAA）商用航行器认证。

自1992年问世以来，uC/os-II已经在世界范围内得到广泛的应用，如手机、路由器、集线器、不间断电源、飞行器、医疗设备及工业控制。

1.4 嵌入式操作系统

(6) pSOSystem

pSOSystem 是一个专门为嵌入式微处理器设计和开发的模块、高效率的实时操作系统。

pSOSystem 的每一部分都是完全“自包含”的，这种机制允许开发者根据每个应用的特殊要求，对操作系统的功能和内存进行裁剪和配置。

pSOSystem 提供了一套集成化的交叉开发工具，以支持应用系统的开发。该集成环境可在 PC 机或工作站上运行，这些工具可通过多种连接机制与目标机通信。

1.5 边缘智能（Edge AI）概念与发展趋势

1.5.1 什么是边缘智能？

1、核心定义

边缘智能（Edge AI）是指将人工智能模型的推理能力部署在靠近数据源头的边缘设备上，而非依赖远程云端服务器进行集中处理的技术范式。它旨在实现低延迟、高隐私、强可靠、低成本的智能服务。

1.5 边缘智能（Edge AI）概念与发展趋势

2、核心特征

(1) 本地化推理：数据“端侧闭环”，摆脱云端依赖

数据在设备端完成处理，无需上传云端。

具体表现

- 数据本地闭环流转
- 离线自主运行

核心价值

- 打破“云端依赖”
 - 降低决策链路
-

1.5 边缘智能（Edge AI）概念与发展趋势

2、核心特征

(2) 实时响应：毫秒级延迟，满足严苛时序需求

边缘设备从采集数据到输出决策结果的总延迟（端到端延迟）控制在毫秒级

具体表现

- 即时反馈
- 时序精度可控

核心价值

- 支撑高时效性场景落地
 - 提升用户体验
-

1.5 边缘智能（Edge AI）概念与发展趋势

2、核心特征

(3) 数据隐私保护：敏感信息 “不出设备”，符合合规要求

用户或场景中的敏感数据全程在边缘设备内存储、处理与销毁，从源头阻断数据泄露风险。

具体表现

- 医疗、消费、工业等场景的原始数据，在设备端存储、处理与销毁，仅把结果信息上传到云端。

核心价值

- 降低隐私泄露风险
 - 减少合规成本
-

1.5 边缘智能（Edge AI）概念与发展趋势

2、核心特征

(4) 带宽与能耗优化：降本增效，适配边缘设备特性

通过 “数据本地预处理 + 仅传有效结果” 的模式，大幅减少网络带宽占用，降低能耗。

具体表现

- 实际带宽节省
- 降低无线通信模块的能耗

核心价值

- 降低运营成本
 - 拓展应用场景
-

1.5 边缘智能（Edge AI）概念与发展趋势

2、核心特征

(5) 云边协同架构：“云端赋能+边缘执行” 兼顾全局与局部

边缘设备与云端服务器形成“分工协同、优势互补”的智能体系：边缘负责实时推理、本地决策与数据预处理；云端负责模型训练、全局优化、模型更新与海量数据存储，两者通过轻量化通信协议实现高效协同。

核心价值

- 兼顾局部效率与全局优化
 - 提升系统弹性
-

1.5 边缘智能（Edge AI）概念与发展趋势

2、核心特征

边缘智能的五大核心特征并非孤立存在，而是形成“架构支撑（本地化推理 + 云边协同）→ 性能保障（实时响应）→ 资源优化（带宽与能耗优化）→ 安全合规（数据隐私保护）”的完整逻辑链。

这些特征共同支撑边缘智能从“云端 AI 的补充”升级为“智能时代的神经末梢”，成为自动驾驶、智能制造、智慧城市等关键场景不可或缺的技术支撑，推动智能服务从“集中式”向“分布式”转型。

1.5 边缘智能（Edge AI）概念与发展趋势

1.5.2 边缘智能发展历程

萌芽期 (1990s–2010s)

内容分发网络CDN、雾计算初步探索，但缺乏AI能力

技术融合期 (2015–2020)

深度学习兴起，轻量化框架出现。

规模化落地期 (2021–2024)

TinyML成熟，AI芯片普及，试点应用。

爆发与生态构建 (2025–今)

成为第四次工业革命的关键基础设施。

1.5 边缘智能（Edge AI）概念与发展趋势

1.5.3 核心技术

1、模型轻量化

模型轻量化是边缘智能的核心支撑技术，其本质是在保证 AI 模型核心任务精度的前提下，通过算法优化、结构重构、参数精简等手段，降低模型对内存、算力、功耗的需求，使其能够适配边缘设备的资源约束。

模型轻量化的核心目标：实现精度、体积、算力、功耗的四维平衡。

1.5 边缘智能（Edge AI）概念与发展趋势

(1) 量化：参数“瘦身”，降低计算复杂度

通过减少模型权重、激活值的数据类型位数，降低内存占用与计算量。

传统深度学习模型采用 32 位浮点数（FP32）存储参数，量化后可转为 8 位整数（INT8）、4 位整数（INT4）甚至 2 位到 1 位二进制（Binary），同时通过精度补偿算法控制性能损失。

1.5 边缘智能（Edge AI）概念与发展趋势

(1) 量化：参数“瘦身”，降低计算复杂度

- 体积与算力优化：INT8 量化可使模型体积缩小 4 倍、计算量降低 75%，推理速度提升 3~5 倍；INT4 量化体积缩小 8 倍，速度提升 6~10 倍；
- 比如：ARM Ethos-U55 NPU 原生支持 INT8/INT4 量化，搭配 CMSIS-NN 框架，可将 ResNet18 模型（40-45MB）压缩至 5MB。

1.5 边缘智能（Edge AI）概念与发展趋势

(2) 知识蒸馏：“大模型教小模型”，保留核心能力

利用训练成熟的“教师模型”（复杂大模型，如 ResNet50、Vision Transformer）的“知识”（如中间层特征、概率分布），指导“学生模型”（轻量小模型，如 MobileNet、EfficientNet-Lite）训练，使小模型在体积大幅缩小的同时，逼近大模型的精度。

1.5 边缘智能（Edge AI）概念与发展趋势

(2) 知识蒸馏：“大模型教小模型”，保留核心能力

- 知识蒸馏效果举例：

精度与体积平衡：学生模型体积仅为教师模型的 1/10~1/20，精度损失 $\leq 4\%$ ；例如用 ResNet152（教师）蒸馏 MobileNetV2（学生），图像分类 Top-1 准确率仅下降 3.2%，模型体积从 230MB 压缩至 14MB。

1.5 边缘智能（Edge AI）概念与发展趋势

(3) 神经网络架构搜索 (NAS)

NAS 通过 “搜索空间 + 搜索策略 + 评估准则” 的自动化框架，在预设的网络结构空间中，自动搜索出适配边缘设备资源约束（如算力 $\leq 500\text{MOPS}$ 、内存 $\leq 2\text{MB}$ ）的最优轻量架构，无需人工干预。

1.5 边缘智能（Edge AI）概念与发展趋势

(3) 神经网络架构搜索（NAS）

构优化优势：NAS 设计的模型比人工设计更适配边缘，例如 EfficientNet-Lite（NAS 生成）比 MobileNetV2（人工设计）体积小 30%，精度高 2.1%，推理速度快 15%；阿里平头哥的“玄铁 NAS”工具链，针对 RISC-V 架构芯片优化，自动生成的轻量模型在 EA6530 芯片上算力效率达 24TOPS/W，适配智能家居场景。

1.5 边缘智能（Edge AI）概念与发展趋势

(4) 结构剪枝：剔除冗余，精简计算链路

深度学习模型存在大量冗余参数（如贡献度极低的权重、冗余的卷积通道、重复的网络层），结构剪枝通过“识别冗余 - 剔除冗余 - 微调恢复精度”的流程，在不影响核心性能的前提下，精简网络结构，降低计算量与内存占用。

1.5 边缘智能（Edge AI）概念与发展趋势

(4) 结构剪枝：剔除冗余，精简计算链路

压缩效果：通道级剪枝可使模型计算量降低 50%~70%，体积缩小 40%~60%，精度损失 $\leq 3\%$ ；例如对 YOLOv7-tiny 剪枝后，计算量从 6.2G FLOPs 降至 2.8G FLOPs，体积从 11MB 压缩至 5.2MB；智能手表的语音识别模型通过层级剪枝，剔除冗余的 Transformer 层，推理功耗从 15mW 降至 4mW，续航延长 3 倍。

1.5 边缘智能（Edge AI）概念与发展趋势

(5) 模型轻量化的技术融合与优化策略

通过组合使用不同方法，实现 $1+1>2$ 的效果。

1. “NAS + 蒸馏” 融合：例如谷歌 EfficientNet-Lite 系列（NAS 生成架构 + 蒸馏优化），在体积仅为 ResNet50 的 1/10 的前提下，精度高 5%；

1.5 边缘智能（Edge AI）概念与发展趋势

(5) 模型轻量化的技术融合与优化策略

2. “剪枝 + 量化” 融合：例如工业质检模型先剪枝 50% 通道，再 INT8 量化，最终体积压缩至原模型的 1/10，精度损失仅 2.5%；
3. “蒸馏 + 量化 + 剪枝” 三融合：例如用 YOLOv8（教师）蒸馏 YOLOv8-Nano（学生），再剪枝 30% 通道，最后 INT8 量化，模型体积从 28MB 压缩至 3.2MB，推理速度提升 8 倍，精度损失 $\leq 3\%$ 。

1.5 边缘智能（Edge AI）概念与发展趋势

2、硬件加速

硬件加速是边缘智能的算力核心支撑技术，其本质是通过“专用架构设计 + 指令集优化 + 并行计算调度”，针对 AI 推理任务（如卷积、矩阵乘法、激活函数计算）打造专属硬件模块，替代通用 CPU 的串行计算模式，在有限的边缘设备资源（体积、功耗、成本）约束下，实现“算力密度提升、推理延迟降低、能耗效率优化”的目标。

1.5 边缘智能（Edge AI）概念与发展趋势

2、硬件加速

硬件加速的关键技术特性与优化方向

- （一）并行计算架构：提升算力密度的核心
- （二）量化精度适配：平衡精度与效率的关键
- （三）硬件级安全：边缘场景的合规保障
- （四）低功耗设计：延长边缘设备续航的核心

1.5 边缘智能（Edge AI）概念与发展趋势

1.5.4 总结

边缘智能的发展已超越“技术补充”的范畴，迈入“重构智能体系、定义产业规则”的新阶段。2026年及以后，随着模型技术、硬件架构、生态协同的深度突破，边缘智能将从“单点智能”走向“全域协同智能”，从“场景赋能”升级为“生态重构”，推动人类社会进入“万物智联、自主协同”的智能新纪元。

作业

作业见群文件附件：《作业要求》中第1章的内容

作业提交给助教，转换为pdf提交（注：务必是pdf方式）

提交文件命名：学号-姓名-第x章作业

所有作业在本章结束后1周内提交
